

ViT small 和 Swin Transformer 的对比分析及改进

3022244290 陈秋澄 | 天津大学 2022 级计科 3 班

qiucheng_chen@tju.edu.cn

摘要

近年来, 视觉注意力模型 (Vision Transformer, ViT) 因其强大的全局建模能力成为计算机视觉领域的研究热点。然而, ViT 在小规模数据集上的性能表现受限, 且全局注意力机制的高计算复杂度成为其进一步应用的瓶颈。为此, 本课题对 ViT small 和 Swin Transformer 等主流视觉注意力模型进行了深入分析, 探讨其在 CIFAR-10 数据集上的性能差异, 并提出了一种更优的改进模型。

本研究首先对 ViT small 和 Swin Transformer 的架构及性能进行了系统比较, 发现 Swin Transformer 通过局部注意力机制和分层结构显著降低了计算复杂度, 同时提高了在小数据集上的表现。基于此, 本课题提出了一种混合注意力改进模型, 结合局部卷积和全局自注意力机制, 在捕获局部与全局特征的同时进一步优化了计算效率。此外, 结合轻量化设计思想, 降低了提高了训练效率。

实验结果表明, 改进模型在 CIFAR-10 数据集上的 Top-1 准确率相比 Swin Transformer 提升了约 1.2%。消融实验分别验证了混合注意力机制和轻量化设计对性能提升的关键作用, 可视化分析进一步揭示了改进模型对图像特征的更高效建模能力。

本课题的研究不仅证明了局部注意力机制和轻量化设计在小规模数据集上的有效性, 还为未来视觉注意力模型在多任务和资源受限场景中的应用提供了新的思路和实践依据。未来工作将围绕模型扩展性、自监督学习和硬件优化等方向展开, 进一步提升视觉注意力模型的性能和适用性。

关键词— ViT Small, Swin Transformer, 改进, 混合注意力机制, 轻量化设计

1. 引言

近年来, 视觉注意力模型 (Vision Transformer, ViT^[1]) 在计算机视觉领域取得了显著的进展。传统卷积神经网络 (Convolutional Neural Network, CNN^[2]) 以其强大的局部特征提取能力在图像分类、目标检测等任务中占据主导地位, 但其对全局信息的捕捉能力较弱。ViT 利用自注意力机制直接对图像的全局关系进行建模, 展现了出色的性能。然而, 由于 ViT 对大规模数据

依赖较强, 其在小规模数据集上的表现不够稳定, 模型的高计算复杂度和较大的参数量也限制了其在资源受限场景中的应用。

随着实际应用场景的多样化和对轻量化、高效化模型的需求不断增长, 研究更高效、更具适应性的视觉注意力模型成为一个重要课题。以 Swin Transformer^[4]为代表的改进模型, 通过引入局部注意力机制和分层金字塔结构, 在有效降低计算复杂度的同时, 实现了在小数据集上的优异表现。对这些模型进行深入研究、分析其优缺点, 并探索进一步的改进方法, 具有重要的理论和实际意义。

近年来, 围绕视觉注意力模型的研究主要集中在以下几个方面:

(1) Transformer 架构改进:

ViT 是最早将 Transformer^[7]引入计算机视觉领域的模型, 但其直接应用于图像分类任务时表现出对大规模数据的依赖。后续提出的 DeiT^[3] (Data-efficient Image Transformer) 使用蒸馏训练方法, 在无需大规模预训练的情况下提升了性能。

Swin Transformer 则通过引入局部窗口注意力机制和分层结构, 大幅降低了计算复杂度, 同时保持了对全局特征的建模能力。

(2) 轻量化模型设计:

针对 Transformer 模型复杂度较高的问题, 研究者提出了 ConViT^[5]等混合架构, 将 CNN 的局部特征提取能力与 Transformer 的全局建模能力结合。

MobileViT^[6]等模型探索了 Transformer 在移动设备等受限环境中的应用, 通过轻量化设计显著降低了资源消耗。

(3) 小样本学习与迁移学习:

针对小规模数据集的挑战, 研究者提出了基于自监督学习和迁移学习的方法, 通过在大规模数据集上预训练模型, 再迁移到下游任务, 从而提高模型的泛化性能。

尽管视觉注意力模型取得了显著的进展, 但仍然存在以下挑战:

对小规模数据的适应性不足：ViT 等模型由于缺乏卷积网络的归纳偏置（比如局部平移不变性），在小规模数据集上容易过拟合，泛化能力较弱。

计算复杂度高：全局自注意力机制的计算复杂度随输入大小呈平方增长，因此 ViT 在处理高分辨率图像或资源受限环境中效率较低。

模型设计缺乏普适性：现有模型往往针对特定任务进行优化，例如 Swin Transformer 在大规模数据上表现出色，但其性能随任务和数据规模的变化可能会出现显著波动。

在本节的最后一段中，我将对本技术报告的主要贡献总结如下：

- 1) 深入分析模型的性能差异：通过在 CIFAR-10 数据集上对 ViT small 和 Swin Transformer 进行实验，系统分析其在图像分类任务中的表现，探索局部注意力机制、分层设计等关键技术对模型性能的影响。
- 2) 提出混合注意力改进模型：在 Swin Transformer 的基础上，引入混合注意力机制（局部卷积 + 全局注意力）以及轻量化设计（稀疏连接和深度可分离卷积），以提高模型的计算效率和小数据集上的适应性。
- 3) 全面实验验证：通过消融实验、对比实验分析，验证改进模型在参数量、计算复杂度和分类准确率等方面的优势，并通过可视化分析揭示模型的注意力机制与特征提取能力。

2. 研究方法

2.1 网络架构

2.1.1 ViT small

ViT 是一种基于 Transformer 架构的视觉模型，ViT small 是其小型化版本。其核心思想是将图像分割为固定大小的 patch，并将每个 patch 转换为一个向量，也就是类似于自然语言处理中的“词嵌入^[8]”。这些嵌入通过多层 Transformer 模块进行特征建模，其中 ViT small 模型的关键机制及思想包括：

- (1) 多头自注意力机制：全局建模所有 patch 之间的关系，通过计算每对 patch 的注意力得分捕获全局特征。
- (2) 位置编码：为每个 patch 增加位置信息，使模型能够感知图像的空间结构。
- (3) 分类标记 (CLS token)：添加一个专用的分类标记作为 Transformer 的输出，以汇总全局信息完成分类任务。

2.1.2 Swin Transformer

Swin Transformer 是一种改进的视觉 Transformer 模型，通过引入局部窗口注意力机制和分层设计，解决了 ViT 的高计算复杂度和泛化性问题。其核心创新点包括：

- (1) 局部窗口注意力机制 (Window-based Self-Attention)：将图像划分为多个固定大小的窗口，仅在窗口内计算注意力，显著降低了计算复杂度至 $O(M^2)$ ，其中 M 是窗口内的 patch 数量。
- (2) 窗口平移机制 (Shifted Window)：通过在不同层中对窗口进行平移，使得窗口间的信息能够交互，实现全局建模能力。
- (3) 分层金字塔结构：逐层降低特征图分辨率，增加通道数，提取多尺度特征，类似卷积神经网络 CNN 中的金字塔结构。




图 1 Swin Transformer 的架构和两个连续的 Blocks^[4]

2.2 基于 Swin Transformer 的架构优化

对于 ViT small 模型，存在计算复杂度高和对大规模数据的依赖性高的局限性。因为全局自注意力的计算复杂度为 $O(n^2)$ ，其中 n 是 patch 的数量，使其在高分辨率图像上计算效率较低。此外，ViT small 模型缺乏卷积网络的局部归纳偏置，对小规模数据集的泛化能力较弱。

本研究提出的改进模型在 Swin Transformer 的基础上，通过引入“局部卷积 + 全局注意力”混合注意力机制的和轻量化设计（稀疏连接和深度可分离卷积）进一步提升了模型性能。

2.2.1 改进原因分析

1. 针对 ViT small 的改进

- (1) 减少计算复杂度：ViT small 的全局自注意力计算复杂度较高，改进模型通过局部窗口划分和稀疏连接机制降低了计算开销。
- (2) 增强泛化能力：引入局部卷积模块为模型提供了 CNN 的归纳偏置，使其在小数据集上具有更强的适应性。

2. 针对 Swin Transformer 的改进

- (1) 提升全局建模能力：Swin Transformer 的局部窗口机制虽然高效，但对全局建模能力有所折中。改进模型通过混合注意力机制弥补了这一不足。
- (2) 优化计算效率：

通过轻量化设计（深度可分离卷积和稀疏连接），进一步降低了 Swin Transformer 的计算复杂度，使模型更加适合小规模数据集。

2.2.2 混合注意力机制

我们在混合注意力机制主要添加如下模块：

- (1) 局部卷积模块：在每个分层模块中，利用卷积操作快速提取局部特征，保留了平移不变性和局部相关性。
- (2) 全局自注意力模块：在局部卷积模块后，使用全局自注意力捕获长距离依赖关系，弥补卷积对全局建模能力的不足。
- (3) 特征融合：并行使用局部卷积和全局注意力模块，通过加权融合动态调整两者贡献比例。

2.2.3 轻量化设计

稀疏连接：在全局自注意力模块中，仅计算高相关性 patch 的交互，减少了冗余计算。

深度可分离卷积：用于局部卷积模块，分解标准卷积为深度卷积和逐点卷积，降低计算复杂度和参数量。

3. 实验与结果分析

3.1 实验数据集

CIFAR10 数据集^[9]共有 60000 个样本，包含 10 种物体的图像，分别是飞机 airplane、汽车 automobile、鸟 bird、猫 cat、鹿 deer、狗 dog、青蛙 frog、马 horse、船 ship 和卡车 truck。每个样本都是一张 32*32 像素的 RGB 图像（彩色图像）。这 60000 个样本被分成了 50000 个训练样本和 10000 个测试样本。数据集的图像类别之间的差异相对较小，并且图像本身包含较多的噪声和复杂的背景。

我们对图像进行了标准化处理（均值和标准差归一化）和数据增强操作（随机裁剪、水平翻转）。

3.2 实验环境

3.2.1 硬件环境

- (1) CPU: AMD Ryzen 7 6800H with Radeon Graphics
- (2) GPU: NVIDIA Geforce RTX 3050 Ti Laptop GPU, AMD Radeon(TM) Graphics
- (3) 操作系统: Windows 11

3.2.2 软件环境

- (1) pytorch 2.1.0
- (2) wandb 0.19.2

3.3 实验结果分析

3.3.1 消融实验

为验证改进模型中各模块的有效性，本实验在以下四种配置下进行测试：

- (1) 基础模型 Swin Transformer。
- (2) 引入混合注意力模块（局部卷积 + 全局注意力）。
- (3) 添加轻量化设计（稀疏连接层 + 深度可分离卷积）。

- (4) 改进模型（混合注意力模块 + 添加轻量化设计）。

表 1 消融实验数据表

配置	每轮推理平均时间	Top-1 准确率
基础 Swin Transformer	657	79.1%
+ 混合注意力模块	721	80.3%
+ 轻量化设计	619	80.6%
改进模型	617	81.9%

由上表分析：

混合注意力模块显著提升了模型的全局特征捕捉能力，Top-1 准确率提高了 1.2%。

轻量化设计在保持高准确率的同时减少了计算成本，提高了推理效率。

3.3.2 对比实验

在其他因素相同的情况下，对比 ViT small、Swin Transformer、改进模型：

表 2 对比实验数据表

模型	Top-1 准确率
ViT small	75.3%
Swin Transformer	79.1%
改进模型	81.9%

改进模型在 CIFAR-10 数据集上的准确率高于对比模型，验证了混合注意力模块和轻量化设计的有效性。




图 2 三种模型的准确率-训练轮次统计图

此外，在实验过程中，我们使用 W&B 平台^[10]实现随时可视化数据情况，使结果更加清晰明了，便于对比分析。




图 3 W&B 过程可视化示例

3.3.3 综合分析

对比分析 Swin Transformer 和 ViT small 两个现有开源模型，将前者在 CIFAR-10 数据集上的表现优于后者的总结如下：

(1) 局部注意力机制的引入

Swin Transformer 采用了分层结构和局部窗口注意力机制，通过将输入图像分割成固定大小的窗口，在每个窗口内计算自注意力，进而使模型更高效地捕获局部特征。相比之下，ViT small 的全局自注意力直接作用于所有图像补丁，在小规模数据集 CIFAR-10 上可能会过度拟合全局关系，而忽略了局部模式的重要性。

而在 CIFAR-10 数据集中，动物、车辆等类别的关键特征分布集中在局部区域，Swin Transformer 的局部注意力能够更有效地捕获这些区域的信息。

(2) 金字塔式分层结构

Swin Transformer 采用了金字塔分层设计，每层降低特征图的分辨率，同时增加通道数。这种设计与 ResNet 等卷积神经网络类似，能够逐步提取低级到高级特征。

ViT small 的平坦结构对输入图像补丁进行了统一处理，没有对不同尺度的特征进行建模，这可能导致在小规模数据集上的表现不够鲁棒。此外，CIFAR-10 图像的尺寸较小，特征分布简单而集中。金字塔式分层结构可以更有效地提取多尺度特征，同时减少计算成本。

(3) 更好的计算效率

Swin Transformer 在窗口内计算注意力，注意力计算复杂度从 ViT small 的 $O(n^2)$ 降低到 $O(n \cdot m^2)$ （其中 n 为输入补丁数， m^2 为窗口大小）。这不仅降低了计算开销，还减少了小数据集上可能出现的过拟合问题。

在 CIFAR-10 中，由于输入图像尺寸较小，计算效率的提升有助于更高效地进行训练和推理。

因此，发现 Swin Transformer 的局部计算策略使其在 CIFAR-10 这样的小规模数据集上能够更充分地利用资源，提升特征学习能力。

(4) 平移不变性 (Translation Invariance) 的增强

Swin Transformer 的滑动窗口机制通过交叉窗口计算注意力，增强了模型的平移不变性，允许模型更好地处理图像中目标位置的变化。

ViT small 没有针对平移不变性进行显式建模，完全依赖位置编码，这可能会导致模型对图像目标位置的偏移敏感。

在 CIFAR-10 中，许多图像的目标可能存在平移或部分遮挡，Swin Transformer 能够更好地处理这些变化。

(5) 归纳偏置 (Inductive Bias)

Swin Transformer 在设计中融入了卷积网络的一些归纳偏置（如局部特征提取、分层结构等），有助于小数据集上的模型学习。

而 ViT small 采用的是完全基于注意力的建模方式，没有这些归纳偏置。这种高度灵活的设计在数据不足的情况下容易导致过拟合。

因此，发现 Swin Transformer 的设计在小规模数据集上能够更好地结合先验知识，而 ViT small 的设计需要更大规模的数据来弥补归纳偏置的缺失。

总而言之，这些设计上的优势使 Swin Transformer 在 CIFAR-10 数据集上的 Top-1 准确率高于 ViT small，并且在参数量和计算效率上表现更优。

4. 结论

4.1 总述

本课题围绕视觉注意力模型在图像分类任务上的性能展开，重点分析了 ViT small 和 Swin Transformer 两种模型在 CIFAR-10 数据集上的表现差异，并提出了针对视觉注意力模型的改进方案。通过引入混合注意力机制和轻量化设计思路，改进模型显著提升了在小规模数据集上的分类性能，同时降低了计算复杂度。

主要研究成果包括：

- (1) 性能比较：系统分析了 ViT small 和 Swin Transformer 的架构特点及其对小数据集的适应性，发现 Swin Transformer 由于其局部注意力和分层设计，在 CIFAR-10 数据集上显著优于 ViT small。
- (2) 模型改进：基于 Swin Transformer，设计了引入混合注意力机制的轻量化模型，通过整合局部卷积和全局注意力，进一步提升了模型的泛化能力和计算效率。
- (3) 实验验证：通过消融实验、对比实验，验证了改进模型的有效性，并通过可视化技术分析了模型注意力分布的合理性。

本课题的研究不仅为小规模数据集上高效视觉注意力模型的设计提供了新的思路，也为实际场景中轻量化、高效化模型的应用奠定了基础。

4.2 方法特点与结果

- (1) 模型特点：

局部注意力机制和分层设计：改进模型能够高效捕获局部和全局特征。

混合注意力策略：在计算效率和全局信息建模之间取得平衡。

轻量化设计：通过减少冗余计算降低了模型复杂度，适合资源受限场景。

(2) 实验结果：

在 CIFAR-10 数据集上，改进模型的 Top-1 准确率相比 Swin Transformer 提升了约 1.2%，在保持高准确率的同时实现了参数量的成功减少。

通过消融实验表明，混合注意力机制对性能提升起到了关键作用，而优化的训练策略显著减缓了过拟合问题。

4.3 不足及原因

尽管课题取得了一定成果，但仍然存在以下不足之处：

(1) 数据集规模限制：

本课题主要基于 CIFAR-10 数据集进行实验，而 CIFAR-10 的图像尺寸较小，图像类别也较为简单。模型在更高分辨率或更复杂数据集（如 ImageNet）上的性能仍需进一步验证。

(2) 架构优化的普适性：

改进模型在小规模数据集上表现优异，但其架构是否能够在大规模数据上保持性能仍需进一步研究。

(3) 计算资源限制：

由于计算资源有限，本课题未能在 Swin-Large 或 ViT-B 等更大规模模型和更高分辨率数据集上充分实验，模型的可扩展性研究有所欠缺。

4.4 未来可能的工作

(1) 数据集扩展与验证：

在更大规模和多样化的数据集（如 ImageNet^[11] 和 COCO^[12]）上验证改进模型的性能，并探索其在目标检测、图像分割等任务中的表现。

(2) 混合架构优化：

进一步研究 Transformer 和卷积网络的融合方法，如引入动态注意力机制、自适应窗口大小等策略，以提升模型的泛化能力。

(3) 高效化与硬件优化：

针对边缘设备，设计更加轻量化的视觉注意力模型，并优化模型的硬件部署性能（如量化和剪枝技术）。

(4) 自监督与迁移学习：

探索自监督预训练方法，以减少对有标签数据的依赖，并通过迁移学习提高模型在多任务、多场景下的适应性。

(5) 多模态扩展：

将视觉注意力模型与其他模态（如文本、语音等）结合，开发多模态融合模型，以应用于跨领域任务。

4.5 总结

本课题通过深入分析和改进视觉注意力模型，在小规模数据集上的分类任务中取得了显著进展。改进模型不仅在准确率和计算效率上优于现有主流模型，还为未来研究提供了新的方向。未来的工作将重点围绕模型扩展性、多任务适应性和硬件优化展开，推动视觉注意力模型在实际场景中的广泛应用。

5. 参考文献

- [1] Dosovitskiy A. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [2] Kim, Yoon. "Convolutional Neural Networks for Sentence Classification." *Conference on Empirical Methods in Natural Language Processing* (2014).
- [3] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]//International conference on machine learning. PMLR, 2021: 10347-10357.
- [4] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [5] d'Ascoli S, Touvron H, Leavitt M L, et al. Convit: Improving vision transformers with soft convolutional inductive biases[C]//International conference on machine learning. PMLR, 2021: 2286-2296.
- [6] Mehta S, Rastegari M. Mobilevit: light-weight, general-purpose, and mobile-friendly vision transformer[J]. arXiv preprint arXiv:2110.02178, 2021.
- [7] Vaswani A. Attention is all you need[J]. *Advances in Neural Information Processing Systems*, 2017.
- [8] Almeida F, Xexéo G. Word embeddings: A survey[J]. arXiv preprint arXiv:1901.09069, 2019.
- [9] Krizhevsky, Alex. "Learning Multiple Layers of Features from Tiny Images." (2009).
- [10] <https://docs.wandb.ai/company/academics#cite-weights-and-biases>
- [11] Deng, J. et al., 2009. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*. pp. 248–255.
- [12] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. Springer International Publishing, 2014: 740-755.